RECOPILACIÓN, ESTRUCTURACIÓN Y ANÁLISIS DE DATOS

PRÁCTICA 1

Ingeniería de la ciberseguridad.
Lucía Castro Rodríguez,
Oleg Fomenkov,
Mónica Ramos Martínez,
Álvaro Sierra Parra.

ÍNDICE

INTRODUCCIÓN 3
EJERCICIOS POR RESOLVER 6
1. EJERCICIO: UML y BPMN 6
2. EJERCICIO: Sistema ETL 8
3. EJERCICIO 11
4. EJERCICIO: Funciones del MIS 13
CONCLUSIONES 19

INTRODUCCIÓN

En esta práctica, vamos a analizar el funcionamiento y los datos de una empresa. Como se indica en el enunciado, empezamos con una modelación de cómo es el funcionamiento de la empresa, tanto en UML como en BPMN, y luego se utilizará *Python* y *SQLite* para crear un pequeño MIS (Management Information System) que analizará los datos en la BD mediante el uso de la librería *Pandas*.

El primer paso antes del desarrollo del código es la creación de la base de datos y la inserción de los datos presentes en los ficheros .json. Para ello, utilizamos la librería *sqlite3*, que nos permite crear una base de datos y manipularla utilizando el código en Python.

```
    cursor_user.execute("""
                        CREATE TABLE IF NOT EXISTS user_data_online(
                        username TEXT PRIMARY KEY,
                        tel_num INTEGER,
                        hash_password TEXT NOT NULL,
                        pass_complexity INTEGER NOT NULL,
                        province TEXT,
                        permisos INTEGER,
                        emails_total INTEGER,
                        emails_phishing INTEGER,
                        emails_clicados INTEGER
                        );
                        """)
    # La de las fechas y las IPs de los usuarios
    cursor_user.execute("DROP TABLE IF EXISTS users_ips_fechas;")
    cursor_user.execute("""
                            CREATE TABLE IF NOT EXISTS users_ips_fechas(
                            id INTEGER PRIMARY KEY AUTOINCREMENT,
                            username_access TEXT NOT NULL,
                            ip_address TEXT,
                            fecha DATETIME,
                            foreign key (username_access) REFERENCES user_data_online(username)
                            );
                            """)
```

Ilustración 1: Creación de las bases de datos user_data_online y users_ips_fechas.

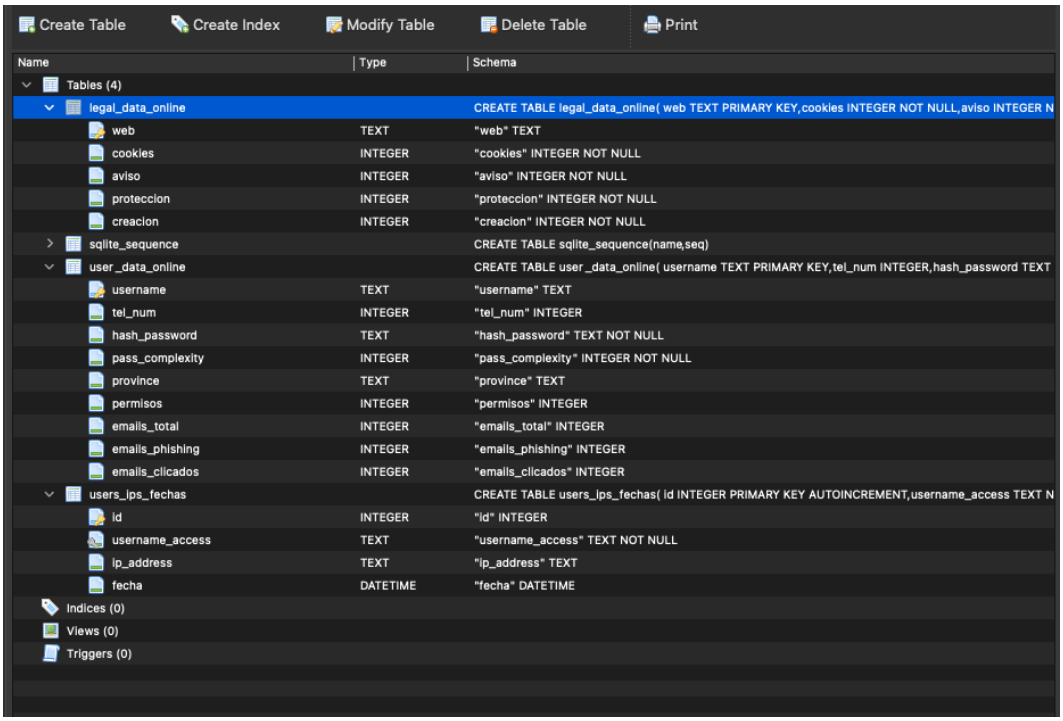

Ilustración 2: Visualización de las tablas en SQLite.

Para la introducir los datos a la base de datos debemos iterar por los ficheros .json y crear sentencias 'INSERT INTO' de SQL. Durante el desarrollo nos enfrentamos a una duda, la clasificación de las contraseñas por nivel de complejidad. Para ello, consultando en Internet, hemos encontrado un fichero llamado 'RockYou.txt' (indicado en el enunciado de la práctica). En este fichero había las 512 contraseñas más comunes, de las cuales algunas han sido utilizadas por los usuarios, por lo que se guardó su hash en la base de datos.

Para comprobar si una contraseña es conocida o no, creamos una función que itera por el fichero de contraseñas, los hashea y los guarda en un array. Posteriormente, para la comprobación, se itera por este array y si la contraseña analizada forma parte de este array, se marca como una contraseña no segura.

```
hashes = []
palabras = open('palabras_comunes.txt', 'r')
for palabra in palabras:
    # Para hashearlas usamos md5
    hash_pass = hash.md5(palabra[:-1].encode(encoding="utf-8")).hexdigest()
    hashes.append(hash_pass)
```

Ilustración 3: Creación del array de contraseñas conocidas hasheadas.

```
# Función para verificar si una contraseña es segura o no
AlexJ *
def if_secure(password, hashes):
    for h in hashes:
        if password == h:
            return 0
    return 1
```

Ilustración 4: Función de comprobación de la contraseña.

Posteriormente, se hace *insert* de todos los datos sacados de los ficheros .json y se hace commit a la base de datos. Este código se puede encontrar en el fichero *creacionDeTablas.py* y la base de datos en el fichero *users_data_online.db*. Las contraseñas conocidas se encuentran en el fichero *palabras_comunes.txt*.

EJERCICIOS POR RESOLVER

1. EJERCICIO: UML y BPMN

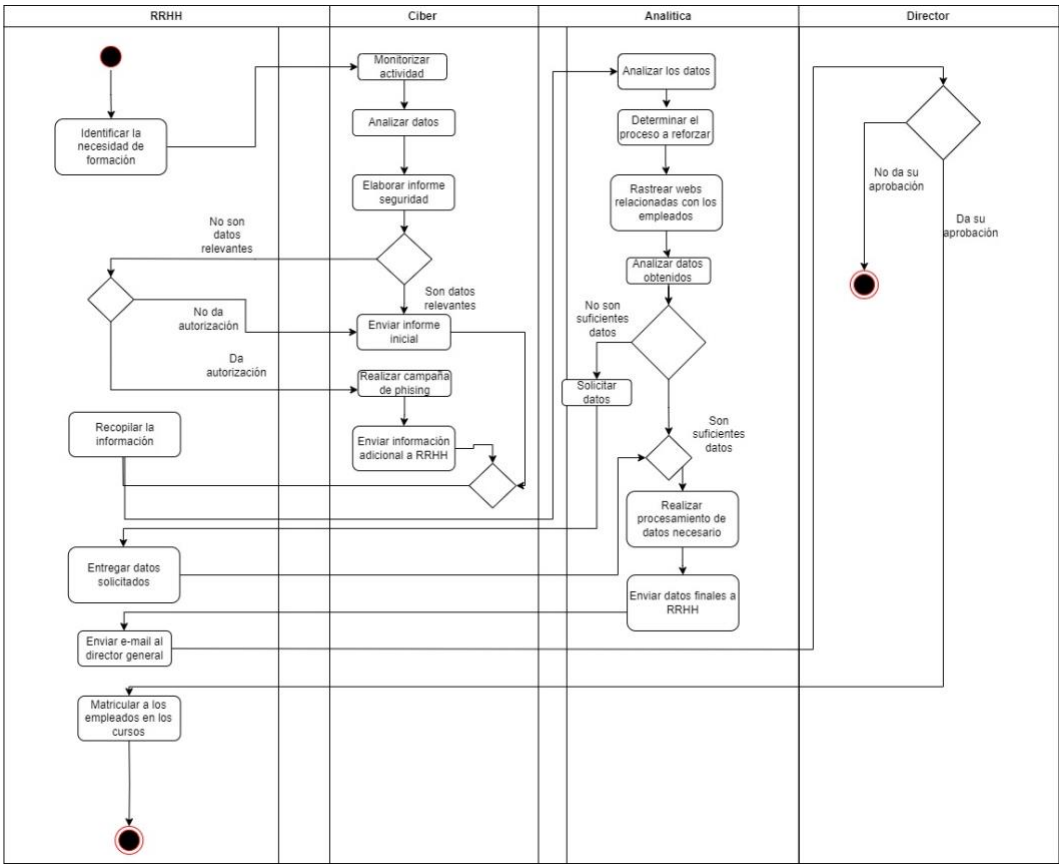

Ilustración 5: UML

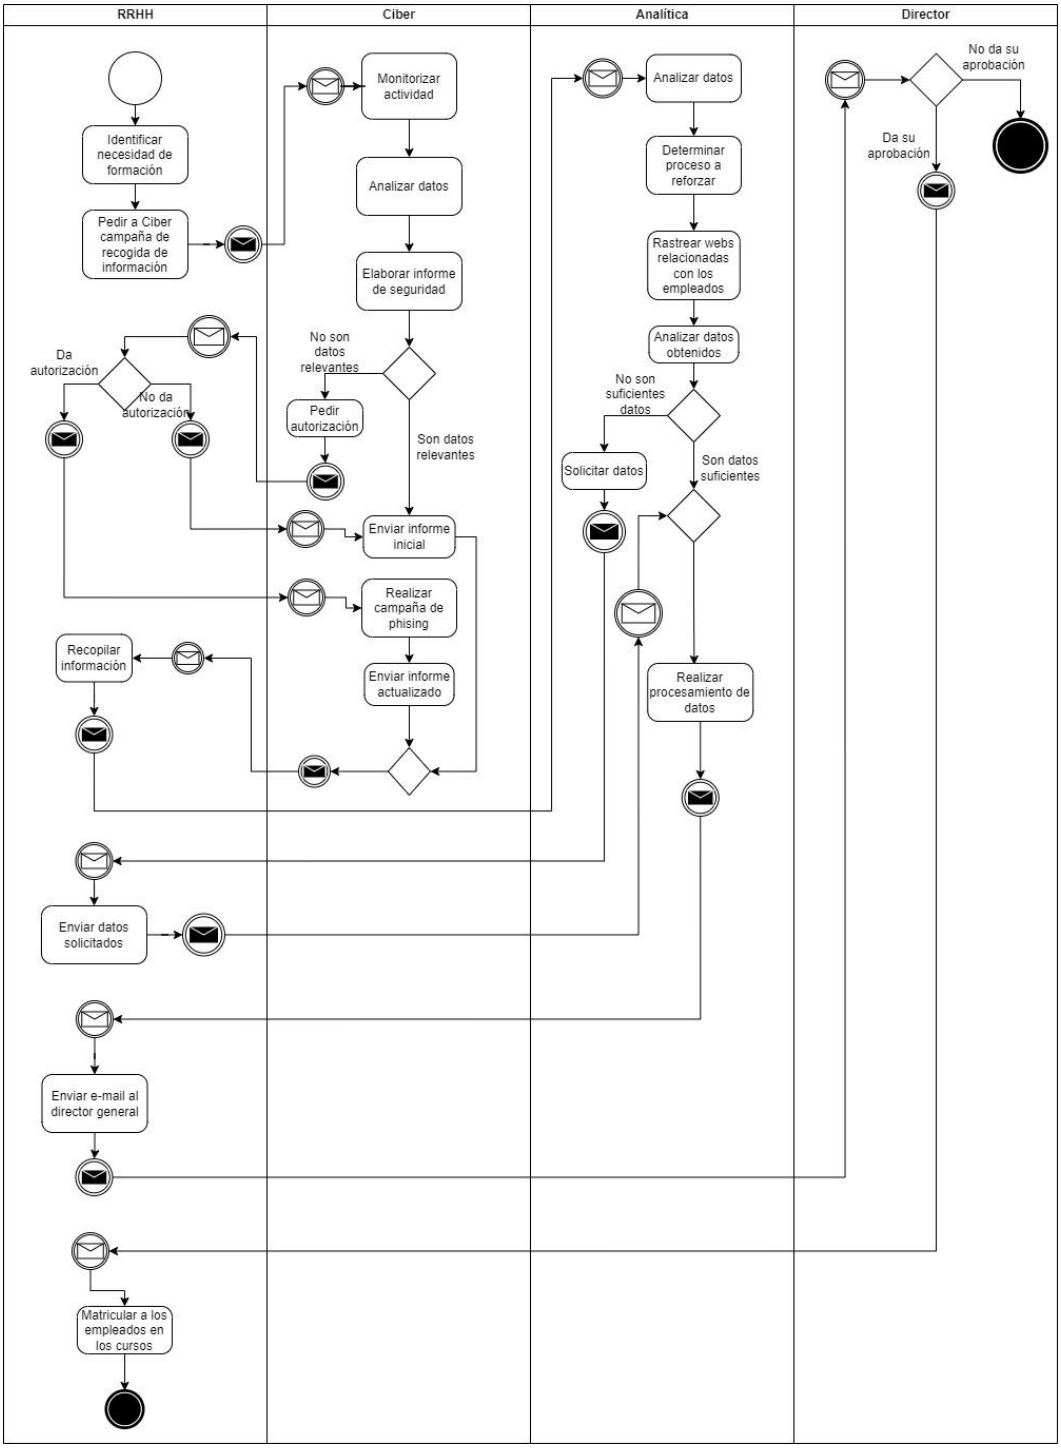

Ilustración 6: BPMN

2. EJERCICIO: Sistema ETL

En este ejercicio desarrollamos un sencillo sistema ETL, donde almacenamos los datos en diferentes dataframes (df_users y df_fechas) para poder manipularlos. Los datos han sido extraídos de los ficheros .json que posteriormente han sido almacenados en la BD en distintas tablas. Para este ejercicio, hicimos 2 versiones: la primera sin filtrar los valores a None y la segunda sí, para comparar los diferentes valores de salida.

```
# Conectamos con la base de datos
conn = sqlite3.connect('users_data_online.db')

# CONSULTAS SIN FILTRADO

# Hacemos las consultas para obtener la información necesaria de las tablas de usuarios e IPs-fechas
query_users = "SELECT * FROM user_data_online;"
query_ips = "SELECT * FROM users_ips_fechas WHERE username_access IN (SELECT username FROM user_data_online);"

#Creamos los DataFrames de pandas con los resultados de las consultas
df_users = pd.read_sql_query(query_users, conn)
df_fechas = pd.read_sql_query(query_ips, conn)
```

Ilustración 7: Consultas sin filtrado de None

En primer lugar, para que el desarrollo del sistema MIS sea correcto, hemos calculado, como indica el enunciado de la práctica, lo siguiente: el número de muestras, la media y la desviación estándar del total de fechas en las que se ha cambiado la contraseña, la media y la desviación estándar del total de IPs que se han detectado, la media y la desviación estándar del número de email recibidos de phishing en los que ha interactuado cualquier usuario, el valor mínimo y el valor máximo del total de emails recibidos, y el valor mínimo y el valor máximo del número de emails de phishing en los que ha interactuado un administrador.

Para realizar los cálculos, hemos utilizado diferentes funciones que pertenecen a la librería Pandas que está especializada en el manejo y análisis de estructuras de datos.

```
# pregunta 2
print("Media de fechas por usuario:")
# agrupamos las fechas por usuarios y se calcula la cantidad media por usuario
print(df_fechas.groupby('username_access').count().mean()['fecha'])
print("Desviación estándar de fechas por usuario:")
print(df_fechas.groupby('username_access').count().std()['fecha'])
print()
```

Ilustración 8: Ejemplos de cálculos

Se destaca que antes de realizar el filtrado, nos encontramos con un total de 30 usuarios con 292 fechas-IPs, y tras el filtrado, únicamente, hay 19 usuarios y 170 muestras de fechas-IPs, Por lo que observamos, que el filtrado recude casi a la mitad del total de las muestras.

```
Numero de muestras de usuarios después del filtrado:
30
Numero de muestras de fechas-ips después del filtrado:
292

Media de fechas por usuario:
9.733333333333333
Desviación estándar de fechas por usuario:
6.141623582562273

Media de IPs por usuario:
9.733333333333333
Desviación estándar de IPs por usuario:
6.141623582562273

La media de los emails recibidos de phishing por usuario:
109.33333333333333

El valor mínimo de los emails recibidos en total:
20
El valor máximo de los emails recibidos en total:
493

Valor mínimo de emails de phishing clicados por usuario con permisos de administrador:
0
Valor máximo de emails de phishing clicados por usuario con permisos de administrador:
301
```

DATOS FILTRANDO NONE

##

Numero de muestras de usuarios después del filtrado:
19
Numero de muestras de fechas-ips después del filtrado:
170

Media de fechas por usuario:
8.947368421052632
Desviación estándar de fechas por usuario:
5.929902418257696

Media de IPs por usuario:
8.947368421052632
Desviación estándar de IPs por usuario:
5.929902418257696

La media de los emails recibidos de phishing por usuario:
112.15789473684211

El valor mínimo de los emails recibidos en total:
35
El valor máximo de los emails recibidos en total:
448

Valor mínimo de emails de phishing clicados por usuario con permisos de administrador:
4
Valor máximo de emails de phishing clicados por usuario con permisos de administrador:
301

3. EJERCICIO

En este ejercicio haremos cuatro agrupaciones, por tipo de permiso (usuario y administrador), y por contraseña (débil o no). Para ello, hacemos diferentes dataframes como en el ejercicio anterior:

Primero, lo hacemos para los tipos de permiso y creamos df_p0 y df_p1.

```
# Hacemos las consultas para obtener los ususarios con permiso 0 o 1 respectivamente
query_permisos_0 = "SELECT * FROM user_data_online WHERE permisos=0"
query_permisos_1 = "SELECT * FROM user_data_online WHERE permisos=1"

# Y se crean los correspondientes DataFrames
df_p0 = pd.read_sql_query(query_permisos_0, conn)
df_p1 = pd.read_sql_query(query_permisos_1, conn)
```

Ilustración 9

Después, para las contraseñas con df_pwd_sec y df_pwd_nosec (separando los dataframes por la complejidad de las contraseñas).

```
# Lo mismo para las contraseñas seguras e inseguras
query_pass_sec = "SELECT * FROM user_data_online WHERE pass_complexity=true"
query_pass_noSec = "SELECT * FROM user_data_online WHERE pass_complexity=false"

df_pwd_sec = pd.read_sql_query(query_pass_sec, conn)
df_pwd_nosec = pd.read_sql_query(query_pass_noSec, conn)
```

Ilustración 10

Tras hacer las dos agrupaciones, calcularemos lo requerido para la variable dentro del email de phishing, utilizando las funciones de la librería Pandas al igual que en el ejercicio anterior, y obtenemos estos resultados:

PERMISOS DE USUARIO
Numero de observaciones de emails phishing:
16

Numero missings:
1

Mediana:
41.0

Media:
79.8125

Varianza:
9881.229166666666

Valor maximo:
382

Valor minimo:
0

PERMISOS DE ADMIN
Numero de observaciones de emails phishing:
14

Numero missings:
0

Mediana:
138.0

Media:
143.07142857142858

Varianza:
12490.840659340658

Valor maximo:
372

Valor minimo:
1

CONTRASEÑA SEGURA
Numero de observaciones de emails phishing:
16

Numero missings:
0

Mediana:
99.0

Media:
119.5

Varianza:
12071.066666666668

Valor maximo:
382

Valor minimo:
1

CONTRASEÑA DEBIL
Numero de observaciones de emails phishing:
14

Numero missings:
1

Mediana:
45.0

Media:
97.71428571428571

Varianza:
11989.912087912086

Valor maximo:
372

Valor minimo:
0

4. EJERCICIO: Funciones del MIS

En este ejercicio, se utilizará la librería Matplotlib.pyplot para hacer los diferentes gráficos, y la librería Pandas.

A continuación, se programan diferentes funciones del MIS para:

- Mostrar la media de tiempo entre cambios de contraseña por usuario de usuarios normales frente a las de usuarios administradores

Primero, como en los anteriores ejercicios, se hacen las consultas para obtener los datos y se almacenan en los dataframes.

```
# Se hacen las consultas para obtener los datos de usuarios normales y admins
query_ips_normal = "SELECT * FROM users_ips_fechas WHERE username_access IN (SELECT username FROM user_data_online  WHERE pe
query_ips_admin = "SELECT * FROM users_ips_fechas WHERE username_access IN (SELECT username FROM user_data_online  WHERE per
# Y se crean los DataFrames correspondientes
df_ips_normal = pd.read_sql_query(query_ips_normal, conn)
df_ips_admin = pd.read_sql_query(query_ips_admin, conn)
```

Ilustración 11

Una vez creados los dataframes, se convierte la columna “fecha” en formato datatime para poder ordenar los datos según la fecha y usuario, y calcular la diferencia en días de las fechas consecutivas.

```
# Convertir la columna "fecha" al tipo datetime
df_ips_normal['fecha'] = pd.to_datetime(df_ips_normal['fecha'], format="%d/%m/%Y")
df_ips_admin['fecha'] = pd.to_datetime(df_ips_admin['fecha'], format="%d/%m/%Y")

# Ordenar los DataFrames segun el nombre de usuario y la fecha
df_ips_normal = df_ips_normal.sort_values(by=['username_access', 'fecha'])
df_ips_admin = df_ips_admin.sort_values(by=['username_access', 'fecha'])

# Calcular la diferencia en dias de las fechas consecutivas, por usuario
df_ips_normal['diferencia'] = pd.to_numeric(df_ips_normal.groupby('username_access')['fecha'].diff().dt.days)
df_ips_admin['diferencia'] = pd.to_numeric(df_ips_admin.groupby('username_access')['fecha'].diff().dt.days)
```

Ilustración 12

Posteriormente, se muestran los datos y se crean los gráficos de barras para comparar resultados:

La media de tiempo medio entre cambios de contraseña por usuario normal (en días):

username_access
antonio.lozano 265.125000
eduardo.galan 236.500000
enrique.sanz 270.500000
fran.moreno 220.375000
ines.lopez 1298.000000
ivan.fernandez 261.333333
javier.osorio 156.200000
jesus.duarte 303.666667
jose.suarez 799.000000
juan.munoz 120.611111
juana.diaz 241.444444
julio.martinez 134.692308
leo.moran 261.875000
luis.garcia 135.928571
raul.perez 96.631579
virgnia.cruz 117.470588

La media de tiempo medio entre cambios de contraseña por usuario administrador (en días):

username_access
administrador 416.500000
alicia.vazquez 110.000000
ceo 102.210526
clara.marin 284.200000
contacto 109.789474
contrataciones 138.142857
directivo 162.461538
info 453.666667
inteligencia-artificial 147.333333
josemaria.lozano 862.000000
legal 248.333333
no-reply 432.666667
personal 186.666667
pruebas NaN

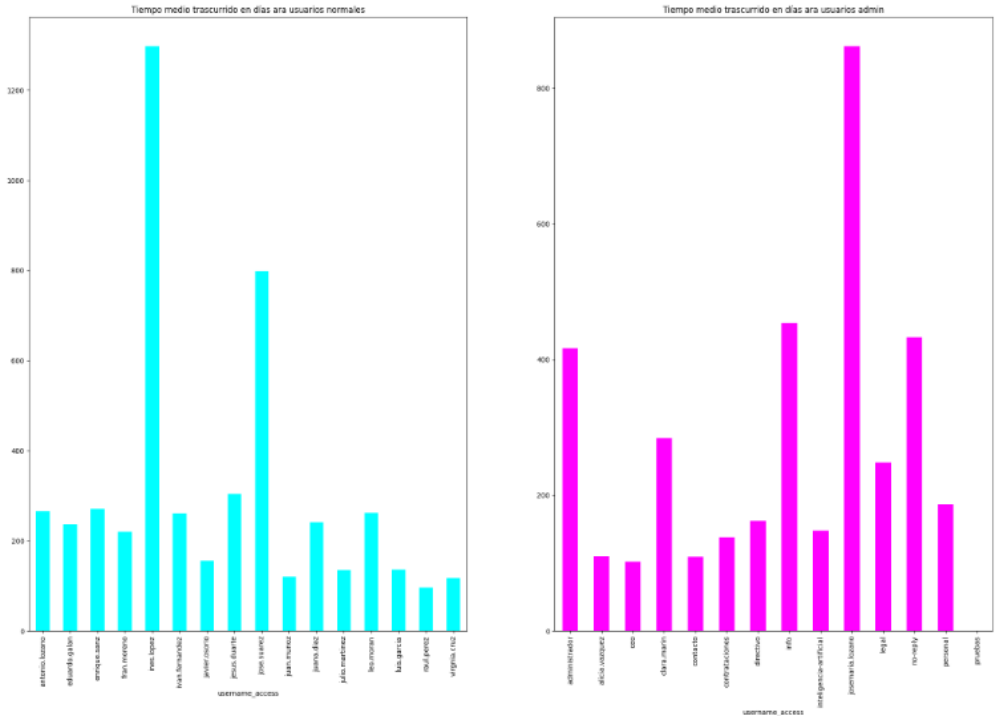

- Mostrar los 10 usuarios más críticos.

Creamos el dataframe con las contraseñas inseguras y calculamos la probabilidad de éxito para el ataque de phishing. Finalmente, se eliminan las columnas que no se mostraran en la gráfica y limitamos a los primeros 10 usuarios.

```
# Hacer consultas de usuarios con contraseñas inseguras y crear DataFrame
query_inseguros = 'SELECT username, emails_clicados, emails_phishing FROM user_data_online WHERE pass_complexity IS
df_inseguros = pd.read_sql_query(query_inseguros, conn)

# Calcular probabilidad de éxito para ataques de phishing
df_inseguros['probabilidad_phishing'] = (df_inseguros['emails_clicados']/df_inseguros['emails_phishing'])*100
df_inseguros.sort_values(by=['probabilidad_phishing'])

# Quitar columnas que no se mostrarán en la gráfica
df_inseguros.drop( labels: ['emails_clicados', 'emails_phishing'], axis=1, inplace=True)
answer += (df_inseguros.to_string())+'\n'

# Limitar DataFrame a los primeros 10 usuarios
df_inseguros = df_inseguros.head(10)
```

Ilustración 13

Estos son los resultados:

```
username probabilidad_phishing
0 jose.suarez 68.253968
1 julio.martinez 51.769912
2 ines.lopez 49.462366
3 josemaria.lozano 72.727273
4 alicia.vazquez 10.303030
5 contacto 56.521739
6 no-reply 83.333333
7 contrataciones 44.878049
8 raul.perez NaN
9 enrique.sanz 25.000000
10 ivan.fernandez 76.666667
11 clara.marin 80.913978
12 virgnia.cruz 42.857143
13 fran.moreno 11.764706
username probabilidad_phishing
0 jose.suarez 68.253968
1 julio.martinez 51.769912
2 ines.lopez 49.462366
3 josemaria.lozano 72.727273
4 alicia.vazquez 10.303030
5 contacto 56.521739
6 no-reply 83.333333
7 contrataciones 44.878049
8 raul.perez NaN
9 enrique.sanz 25.000000
```

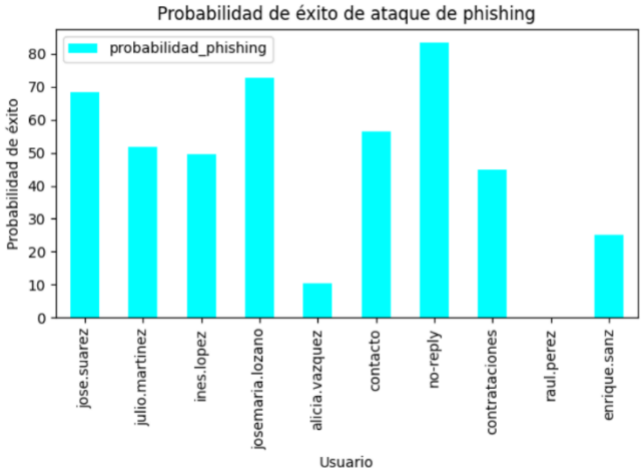

- Mostrar las 5 páginas web que contienen más políticas (cookies, protección de datos o aviso legal) desactualizadas.

Tras realizar las consultas, en este caso en la tabla de legal, y crear el dataframe, se calcula la cantidad de políticas desactualizadas, se ordena y se escogen los 5 primeros para mostrarlo en el gráfico.

```python
# Realizar consultas para obtener datos de la tabla de legal
query_webs = 'SELECT web, cookies, aviso, proteccion FROM legal_data_online;'
df_webs = pd.read_sql_query(query_webs, conn)

# Calcular la cantidad de políticas desactualizadas
df_webs['desactualizadas'] = df_webs[['cookies', 'aviso', 'proteccion']].apply(lambda row: sum(row == 0), axis=1)

# Para que en la gráfica aparezca con el nombre del sitio web
df_webs = df_webs.set_index('web')
answer+=(df_webs.to_string())+'\n'

# Ordenar las webs según el número de políticas desactualizadas y quedarse con los 5 primeros
df_webs.sort_values(by=['desactualizadas'], inplace=True, ascending=False)
primeros_cinco = df_webs.head(5)
```

Ilustración 14

Los resultados son los siguientes:

```
cookies aviso proteccion desactualizadas
web
www.nbcckcip.com 0 1 0 2
www.zrejm.com 1 1 1 0
www.hocptvc.com 1 1 1 0
www.ldxtgwxw.com 1 0 1 1
www.cwngoo.com 0 1 1 1
www.tnvpt.com 1 0 1 1
www.lxkwaajoz.com 1 0 0 2
www.bxwtbni.com 1 0 0 2
www.kijwwl.com 0 0 1 2
www.amnoit.com 1 1 1 0
www.gqhnb.com 0 1 0 2
www.lnritj.com 0 0 1 2
www.qoqu.com 1 1 0 1
www.zzvuuuq.com 1 1 1 0
www.vkxbomd.com 0 1 0 2
www.gjww.com 1 1 0 1
www.jvcl.com 1 1 1 0
www.eohqcu.com 0 0 1 2
www.xshd.com 1 1 1 0
www.aetzc.com 1 0 1 1
```

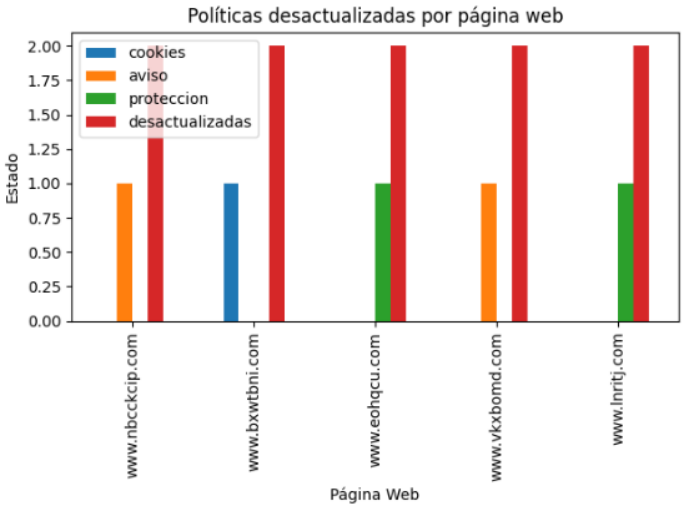

- Mostrar según el año de creación las webs que cumplen todas las políticas de privacidad, frente a las que no cumplen la política de privacidad.

Realizamos las consultas en la tabla de legal y se construye el dataframe, ahora creamos una columna adicional para indicar si se cumplen las políticas de seguridad o no. Posteriormente se agrupan las webs por año de creación y si satisfacen la condición anterior, contando el número de webs de cada categoría. Finalmente creamos el gráfico para mostrarlo.

```python
# Consulta para obtener los datos de la tabla de legal
query_webs = 'SELECT web, creacion, cookies, aviso, proteccion FROM legal_data_online;'
df_webs = pd.read_sql_query(query_webs, conn)

# Creación de columna para indicar si se cumplen las políticas de seguridad
df_webs['satisface'] = (df_webs['cookies'] == 1) & (df_webs['aviso'] == 1) & (df_webs['proteccion'] == 1)

# Agrupar las webs sgún el año de creación y si satisfacen las políticas, contando el numero de webs de cada categoría
df_webs_agrupado_dos_columnas= df_webs.groupby(['creacion', 'satisface']).size().unstack()
answer+=str(df_webs_agrupado_dos_columnas)+'\n'
```

Ilustración 15

Los resultados obtenidos son:

satisface	False	True
creacion		
2001	1.0	1.0
2002	1.0	NaN
2003	1.0	NaN
2007	NaN	1.0
2008	NaN	1.0
2011	1.0	NaN
2012	2.0	NaN
2015	4.0	NaN
2016	1.0	NaN
2017	2.0	NaN
2019	NaN	1.0
2020	1.0	NaN
2022	NaN	2.0

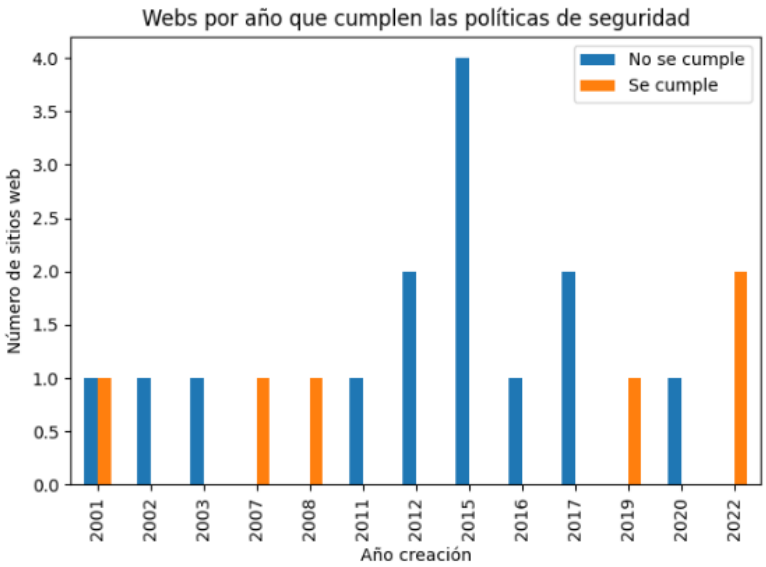

Finalmente, mostramos un ejemplo de cómo se han creado los diferentes gráficos para los apartados anteriores:

```
# Gráfico de barras correspondiente
df_webs_agrupado_dos_columnas.plot(kind='bar')
plt.title('Webs por año que cumplen las políticas de seguridad')
plt.xlabel('Año creación')
plt.ylabel('Número de sitios web')
plt.legend(['No se cumple', 'Se cumple'])
plt.tight_layout()
plt.savefig("static/images/grafico4.png")
```

Ilustración 16

CONCLUSIONES

La práctica se centra en profundizar en conceptos relacionados con la gestión de procesos de negocio y el desarrollo de sistemas de información. El escenario que se plantea implica el análisis de la necesidad de formación en seguridad de informática para los empleados de una compañía que gestionan diferentes sitios web.

Generamos información valiosa a través de la modelización de proceso de negocio, usando UML y BMPN, el desarrollo de un sistema de información gerencial (MIS), mediante el uso de Python y sus diferentes librerías como Pandas, y una base de datos SQLite. Además, se usó el framework Flask para crear una web estática para la presentación de los diferentes informes, de una forma más visual.

En conclusión, esta práctica nos proporcionó la oportunidad de aplicar los conocimientos teóricos obtenidos en el desarrollo de las diferentes clases en un contexto empresarial real. Destacando la importancia de la integración de la información las diferentes áreas funcionales en una única base de datos, además del uso de herramientas tecnológicas para el desempeño en materia de seguridad informática y gestión de procesos de negocio.

Finalmente, este es el enlace para el repositorio de GitHub:

https://github.com/fomenkoleg/PracticaSSII